Tarea S4.01. Creación de Bases de Datos

Nivel 1

Descarga los archivos CSV, estúdialos y diseña una base de datos con un esquema de estrella que contenga, al menos 4 tablas de las que puedas realizar las siguientes consultas:

A continuación mostramos la base de datos con las tablas creadas y el diagrama con esquema de estrella. Para crear la base de datos simplemente usamos CREATE DATABASE con el nombre de la base de datos y luego escribimos USE y el mismo nombre de la base de datos con la que vamos a operar.

```
#NIVEL 1
#Crear Base de datos
CREATE DATABASE transactions_db;
USE transactions_db;
```

Para crear las tablas siempre empezaremos usando la cláusula CREATE TABLE IF NOT EXISTS y el nombre de la tabla. Empezamos con las tablas que contengan solamente claves primarias. La primera será users. Escribimos los nombres de las variables y le asignamos un tipo de dato. Para datos de carácter alfanumérico que pueden variar en longitud o espacio, usamos VARCHAR() y asignamos un número que representa este espacio o longitud que ocupan los datos. Asegurémonos que el número es suficientemente largo ya que si el número de caracteres de una fila supera esta cifra, nos dará error. Si queremos evitar ocupar mucho espacio, también podemos ajustar a una cifra que sabemos no se superará en ninguna fila. La primera variable suele ser una clave primaria id. Si sabemos que hay variables que todas las filas tienen la misma longitud, usamos CHAR(longitud de caracteres). Nos aseguramos siempre de acabar cada tabla con ");".

```
# Tabla users
 7 • ⊝ CREATE TABLE IF NOT EXISTS users (
           id VARCHAR(3) PRIMARY KEY,
 8
9
           name VARCHAR(50),
10
           surname VARCHAR(20),
11
           phone VARCHAR(20),
12
           email VARCHAR(50),
           birth_date VARCHAR(20),
13
           country VARCHAR(20),
14
15
           city VARCHAR(30),
16
           postal_code VARCHAR(25),
           address VARCHAR(50)
17
18
      );
```

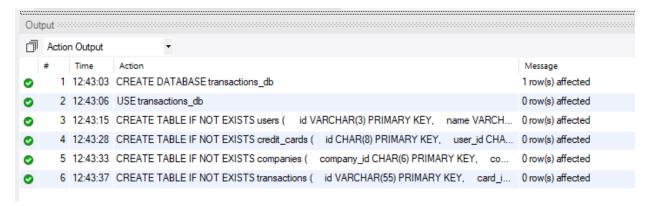
La siguiente tabla, credit_cards, contiene una clave foránea al final. La variable user_id hacer referencia a la id de la tabla users, de modo que usamos FOREIGN KEY (user_id) REFERENCES users(id) para que queden relacionadas ambas tablas.

```
20
       # Tabla credit_cards
21 • ⊝ CREATE TABLE IF NOT EXISTS credit cards (
22
           id CHAR(8) PRIMARY KEY,
23
           user_id CHAR(3),
           iban VARCHAR(34),
24
           pan VARCHAR(19),
25
26
           pin CHAR(4),
27
           cvv CHAR(3),
28
           track1 VARCHAR(50),
           track2 VARCHAR(50),
29
           expiring_date VARCHAR(10),
30
           FOREIGN KEY (user_id) REFERENCES users(id)
31
32
       );
```


```
34
       # Tabla companies
35 • ⊖ CREATE TABLE IF NOT EXISTS companies (
           company_id CHAR(6) PRIMARY KEY,
36
           company_name VARCHAR(35),
37
38
           phone VARCHAR(30),
           email VARCHAR(40),
39
           country VARCHAR(30),
40
           website VARCHAR(50)
41
42
      );
```

En la tabla transactions, incluimos 3 claves foráneas, las variables id de cada una de las 3 tablas creadas anteriormente. Así todas estarán relacionadas y formarán el esquema de estrella requerido. Veremos que algunas variables contienen tipos de dato distintos como timestamp para representar fechas y horas, la variable declined será booleana con 1s y 0s para representar si la transacción está declinada o no y variables de coordenadas como lat y longitud con float o amount con DECIMAL para representar valores con decimales.

```
44
       # Tabla transactions
45 • ○ CREATE TABLE IF NOT EXISTS transactions (
           id VARCHAR(55) PRIMARY KEY,
46
47
           card id CHAR(8),
48
           business_id CHAR(6),
           timestamp TIMESTAMP,
49
           amount DECIMAL(10, 2),
50
           declined BOOLEAN,
51
52
           product ids VARCHAR(50),
53
           user_id CHAR(3),
           lat FLOAT,
54
55
           longitude FLOAT,
           FOREIGN KEY (card id) REFERENCES credit cards(id),
56
57
           FOREIGN KEY (business id) REFERENCES companies(company id),
           FOREIGN KEY (user_id) REFERENCES users(id)
58
59
      );
```



Una vez ejecutamos cada tabla y nos aseguramos que están correctamente creadas, vamos a database, reverse engineer y hacemos click en next, seleccionamos la base de datos transactions_db y seguimos haciendo click en next/finish hasta que nos aparezca el diagrama. Veremos que las relaciones son de N:1 entre transactions y el resto de tablas. Lo que significa que un usuario, una tarjeta de crédito o una compañía pueden tener varias transacciones. Entre users y credit_cards también hay una relación de 1:N, un usuario puede tener varias tarjetas de crédito.



Una vez tenemos la base de datos, las tablas y el esquema, importamos los datos de los archivos csv disponibles en el enunciado.

Para ello usaremos un bloque de código similar en todos los archivos. LOAD DATA INFILE con la ubicación permitida para cargar archivos a MySQL y el nombre del archivo a importar. INTO TABLE con el nombre de la tabla que queramos rellenar, FIELDS TERMINATED BY ',' para indicar si lo valores de cada columna están separados por coma o punto y coma, ENCLOSED BY ' " ' para indicar si hay términos entre comillas, LINES TERMINATED BY con el código que indica fin o nueva línea y por último IGNORE 1 ROWS para ignorar la primera fila con los títulos de cada columna, solamente queremos los datos.

```
#inserción de datos de los 3 archivos csv para users

LOAD DATA INFILE "C:/ProgramData/MySQL/MySQL Server 8.0/Uploads/users_ca.csv"

INTO TABLE users

FIELDS TERMINATED BY ','

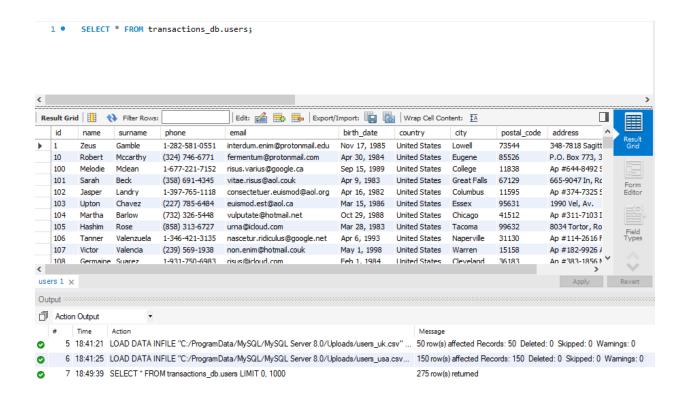
ENCLOSED BY '"'

LINES TERMINATED BY '\r\n'

IGNORE 1 ROWS;
```



Aquí vemos cómo se han importado los valores para la tabla users. Al tener 3 archivos csv, comprobamos con excel que el número total de filas que contiene la tabla en Workbench es el mismo que el total de filas de los 3 archivos csv de 'users_usa', 'users_uk' y 'users_ca'.

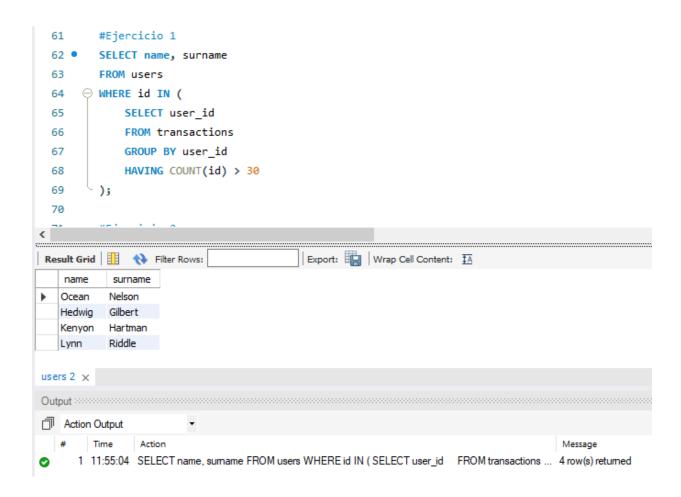


Hacemos exactamente lo mismo para el resto de tablas con sus respectivos datos importados de los archivos csv, proporcionados por el enunciado. Para las demás tablas podemos prescindir de LINES TERMINATED BY. A tener en cuenta también que antes y después de escribir el código con la carga de datos para transactions, al incorporar claves foráneas, debemos usar SET FOREIGN_KEY_CHECKS = 0 antes y SET FOREIGN_KEY_CHECKS = 1 después para evitar errores en el proceso de carga.

Ejercicio 1

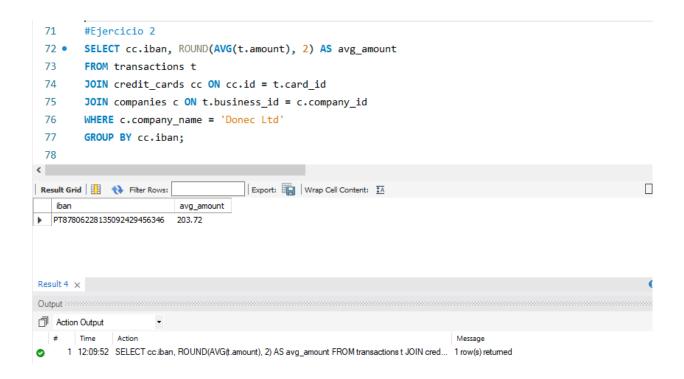
Realiza una subconsulta que muestre a todos los usuarios con más de 30 transacciones utilizando al menos 2 tablas.

Para realizar dicha consulta, seleccionamos el nombre y apellido de la tabla usuarios con el criterio WHERE id IN con la subconsulta que nos seleccione la id del usuario de la tabla transactions agrupado por id de usuario y usando la cláusula HAVING, contamos por id con COUNT(id) el número de transacciones que han realizado. Si queremos seleccionar solamente aquellos usuarios que hayan realizado más de 30, ponemos > 30 al final.



Ejercicio 2 Muestra la media de amount por IBAN de las tarjetas de crédito en la compañía Donec Ltd., utiliza por lo menos 2 tablas.

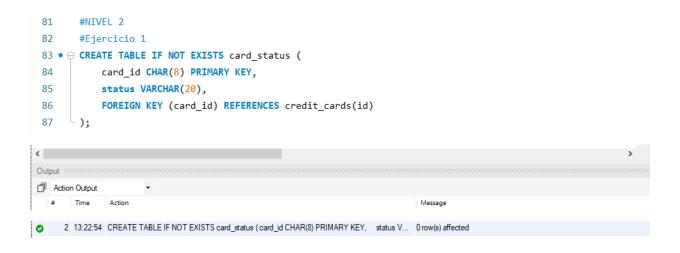
Para este ejercicio seleccionamos variables usando alias ya que utilizaremos JOINS para unir la tabla transactions con credit_cards y companies por medio de las ids de éstas. Seleccionamos de la tabla credit cards (alias cc) la variable iban, para calcular el importe promedio, usamos ROUND(AVG(t.amount, 2) para obtener el cálculo redondeado a 2 decimales, lo renombramos todo con el alias avg_amount. Ponemos en la cláusula FROM la variable con las claves foráneas transactions y hacemos el doble JOIN de credit_cards y transactions por medio de cc.id = t.card_id y companies con transactions por medio de t.business_id = c.company_id. Usamos el criterio WHERE con el nombre de la empresa 'Donec Ltd' para ver la media de importe de las tarjetas de crédito de dicha compañía. Agrupamos por la variable de credit_cards iban.



Nivel 2

Crea una nueva tabla que refleje el estado de las tarjetas de crédito basado en si las últimas tres transacciones fueron declinadas y genera la siguiente consulta:

Tal como nos piden, creamos una tabla llamada card_status con una variable card_id que figure como clave primaria, con referencia a la variable id de la tabla credit_cards y otra variable status que nos represente el estado de la tarjeta de crédito (activada o desactivada), según el criterio establecido en el enunciado.

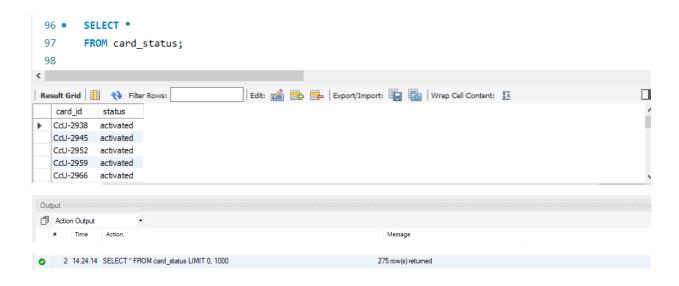


Una vez tenemos la tabla creada, haremos la introducción de los datos. Para ello usamos INSERT INTO card status (card id, status) y en lugar de escribir VALUES como hemos hecho en anteriores ocasiones, haremos una consulta seleccionando card id, usaremos CASE WHEN SUM(declined) = COUNT(*) THEN 'not activated' para determinar que si la suma de todas las transacciones declinadas que cogemos iguala el número total de filas contadas en la selección, la tarjeta está desactivada. Si hay un solo 0, estará activada (ELSE activated'). Finalizamos con END AS status para que se introduzcan los datos correctamente en dicha columna. Para saber de donde coger estos datos, en FROM usaremos una subconsulta seleccionando card id, declined, timestamp y una columna nueva que deberemos crear para poder coger las 3 o menos de 3 transacciones más recientes de cada card id. Creí que usando ORDER BY timestamp y LIMIT 3 podría establecer el criterio que nos dan como requisito para saber el estado de cada tarjeta. Pero haciendo esto solo cogemos las 3 primeras filas. El resto de card ids no se seleccionan. Consultando online vi que se puede establecer dicho criterio si creamos una columna que enumere las transacciones para cada card id. La cláusula es ROW NUMBER() OVER(PARTITION BY card id ORDER BY timestamp DESC) AS row num. Esto nos añadirá dicha columna con un índice que se auto incrementará para cada card id, ordenado según la fecha de más reciente a menos. Las otras columnas seleccionadas las cogemos de la tabla transactions. Cerramos paréntesis de la subconsulta y le añadimos un alias AS LastThreeTransactions. En este caso, si no añadimos alias a la subconsulta nos da error. Añadimos debajo el criterio WHERE row num <= 3 para que se quede con las 3 o menos de 3 transacciones más recientes de la subconsulta y GROUP BY card id. Vemos cómo queda la tabla card status.

```
#Insertar valores de status según las tres últimas transacciones
88 • INSERT INTO card_status (card_id, status)
89
       SELECT card id, CASE WHEN SUM(declined) = COUNT(*) THEN 'not activated' ELSE 'activated' END AS status
90

⊖ FROM (SELECT card_id, declined, timestamp,
91
                      ROW_NUMBER() OVER (PARTITION BY card_id ORDER BY timestamp DESC) AS row_num
              FROM transactions) AS LastThreeTransactions
92
       WHERE row_num <= 3
93
       GROUP BY card id;
Output ::
Action Output
    1 14:24:10 INSERT INTO card_status (card_id, status) SELECT card_id, CASE WHEN SUM(declined) = ... 275 row(s) affected Records: 275 Duplicates: 0 Warnings: 0
```

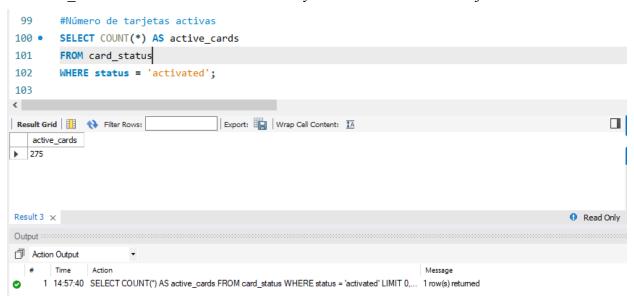
Hacemos una consulta para ver si los datos están bien introducidos



Ejercicio 1

¿Cuántas tarjetas están activas?

Para responder esta pregunta, simplemente hacemos SELECT COUNT(*) AS active_cards de la tabla card status WHERE status = 'activated' y nos contará el total de tarjetas activas.



Según la consulta, todas están activadas, no hay ninguna con sus últimas 3 o menos de 3 transacciones declinadas.

NIVEL 3

Crea una tabla con la que podamos unir los datos del nuevo archivo products.csv con la base de datos creada, teniendo en cuenta que desde transaction tienes product_ids. Genera la siguiente consulta:

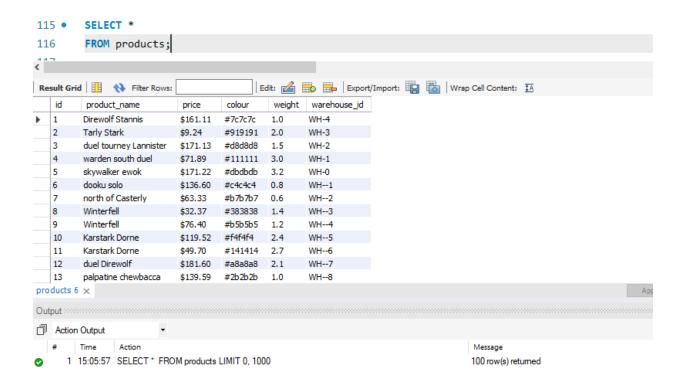
Hacemos el mismo código que usamos para las tablas anteriores. Añadimos las columnas y nos aseguramos de incluir el tipo de dato adecuado para que no hayan errores al importar los datos del archivo csv. Id será la primary key.

```
159
         # Ejercicio 1
160 • ⊖ CREATE TABLE IF NOT EXISTS products (
             id VARCHAR(100) PRIMARY KEY,
162
             product_name VARCHAR(50),
163
             price VARCHAR(20),
             colour CHAR(7),
165
             weight DECIMAL(4, 1),
             warehouse_id VARCHAR(10)
166
167
       ٠);
168
169 • LOAD DATA INFILE "C:/ProgramData/MySQL/MySQL Server 8.0/Uploads/products.csv"
         INTO TABLE products
         FIELDS TERMINATED BY ','
171
         ENCLOSED BY ""
172
173
         IGNORE 1 ROWS:
Output :
Action Output
       Time
               Action
                                                                                 Message
  15 18:50:47 SET FOREIGN_KEY_CHECKS = 1
                                                                                 0 row(s) affected

    16 18:55:12 CREATE TABLE IF NOT EXISTS products ( id VARCHAR(100) PRIMARY KEY, produ... 0 row(s) affected

     17 18:55:17 LOAD DATA INFILE "C:/ProgramData/MySQL/MySQL Server 8.0/Uploads/products.csv" ... 100 row(s) affected Records: 100 Deleted: 0 Skipped: 0 Warnings: 0
```


Importamos los datos y visualizamos la tabla para ver que todo está correcto.



Una vez tenemos la tabla products, debemos relacionarla con transactions. Si nos fijamos en la columna product_ids de transactions, hay varios valores separados por comas en una misma fila o registro. Esto nos puede traer problemas si queremos hacer la relación con products o hacer consultas que impliquen ambas tablas. De modo que hay que separar los valores y hacer que aparezca un solo product_id por fila. Para ello usaremos una CTE (Common Table Expression) que contenga la misma columna de product_ids en transactions pero con un solo valor por fila. El código es bastante difícil de interpretar, primero se crea la tabla transactions_products y luego introducimos valores en esta CTE haciendo la separación de product_ids por ',' e introduciendo un solo valor por fila. Veamos como queda en MySQL y posteriormente describimos cada bloque de código:


```
#Crear un índice en las tabla de referencia si no existe
179
        ALTER TABLE transactions ADD INDEX (id);
180 •
181
182
         # Crear la tabla puente transaction_products
183 • 

    CREATE TABLE IF NOT EXISTS transaction_products (
184
             transaction_id VARCHAR(255),
185
             product_id VARCHAR(100),
             FOREIGN KEY (transaction_id) REFERENCES transactions(id),
186
187
             FOREIGN KEY (product_id) REFERENCES products(id)
188
         );
Output
Action Output
       Time
               Action
     1 19:08:32 ALTER TABLE transactions ADD INDEX (id)
                                                                                   0 row(s) affected Records: 0 Duplicates: 0 Warnings: 0
    2 19:08:33 CREATE TABLE IF NOT EXISTS transaction_products ( transaction_id VARCHAR(255),
                                                                                   0 row(s) affected
```



WITH RECURSIVE numbers crea una secuencia de números del 1 al 5 (se ajusta según el número máximo de productos que pueda ver en una fila de la columna product_ids). SUBSTRING_INDEX extrae cada product_id de la lista de product_ids separada por comas, usando el número generado (n.n) para determinar cuál extraer. JOIN numbers asocia cada fila de la tabla transactions con un conjunto de números, descomponiendo las listas de product_ids en valores individuales. Con INSERT INTO insertamos cada combinación de transaction_id y su respectivo product_id descompuesto en la tabla transaction_products.

Aquí vemos el aspecto que tiene la CTE transaction products:



Una vez tenemos creada la tabla puente, podemos hacer el último ejercicio.

Ejercicio 1

Necesitamos conocer el número de veces que se ha vendido cada producto.

Para ello, seleccionaremos de la tabla puente product_id, el nombre del producto de la tabla products, usamos una función agregada para contar el número de transacciones realizadas según el product_id y usamos como alias total_sales. Hacemos uso de JOIN para unir products y transactions con la tabla puente transaction_products por medio de las ids. Usamos WHERE declined = 0 para coger transacciones aceptadas solamente (ventas) y agrupamos por product_id ya que un producto puede llamarse igual pero tener distintas características. Es importante agrupar por id para sacar el número de veces que se ha vendido un producto concreto. De lo contrario agrupamos por nombre y no obtenemos las cifras correctas. Finalmente, ordenamos de mayor a menor número de veces que se haya vendido un producto con total_sales DESC.

